

Ứng dụng Machine Learning và SHAP trong Dự đoán khả năng vỡ nợ tín dụng

Đỗ Xuân Tú
IS403.Q13
23521698@gm.uit.edu.vn

Phạm Đức Trung
IS403.Q13
23521685@gm.uit.edu.vn

Phan Đức Trí
IS403.Q13
23521646@gm.uit.edu.vn

Trần Minh Triết
IS403.Q13
23521653@gm.uit.edu.vn

Trần Duy Trường
IS403.Q13
23521694@gm.uit.edu.vn

Tóm tắt nội dung—Nghiên cứu này tập trung vào bài toán dự đoán rủi ro tín dụng (credit default prediction), xây dựng một khung mô hình dựa trên machine learning và tiến hành so sánh nhiều thuật toán phân loại phổ biến. Dữ liệu sử dụng là bộ Home Credit, sau khi được tiền xử lý và thực hiện kỹ thuật feature engineering. Các mô hình được đánh giá gồm: Logistic Regression, Random Forest, XGBoost, LightGBM... theo các tiêu chí Precision, Recall, F1-Score và ROC-AUC nhằm đảm bảo đánh giá toàn diện cả độ chính xác, khả năng hồi tưởng và hiệu suất tổng thể của mô hình. Kết quả cho thấy các phương pháp học ensemble (đặc biệt là XGBoost, CatBoost) thể hiện ưu thế rõ rệt về hiệu suất dự đoán. Chúng đặc biệt hiệu quả trong việc xử lý các mối quan hệ phi tuyến phức tạp giữa các đặc trưng và giải quyết vấn đề mất cân bằng dữ liệu, đồng thời duy trì được tính ổn định và khả năng khái quát cao. Trong đó, XGBoost đạt giá trị ROC-AUC cao nhất và F1-Score vượt trội so với các mô hình khác, cho thấy khả năng cân bằng tốt giữa Precision và Recall. Công cụ SHAP được sử dụng để phân tích tầm quan trọng và sự phụ thuộc của các đặc trưng. Kết quả chỉ ra rằng các biến điểm tín dụng bên ngoài (external credit score) đóng vai trò chủ đạo trong quyết định của mô hình, giúp nâng cao tính minh bạch và giá trị ứng dụng thực tiễn. Nghiên cứu này mang lại tham chiếu hữu ích và hỗ trợ kỹ thuật cho việc phát triển hệ thống kiểm soát rủi ro tín dụng thông minh.

Index Terms—Machine Learning, SHAP (SHapley Additive exPlanations), Vỡ nợ tín dụng, Dự báo tài chính, XGBoost (Extreme Gradient Boosting), CatBoost (Categorical Boosting), LightGBM (Light Gradient Boosting Machine), KNN (K-Nearest Neighbors), MLP (Multilayer Perceptron), SVM (Support Vector Machine), ROC-AUC (Receiver Operating Characteristic – Area Under the Curve)

I. GIỚI THIỆU (INTRODUCTION)

Trong lĩnh vực tài chính – ngân hàng, việc đánh giá và dự đoán khả năng vỡ nợ của khách hàng vay vốn đóng vai trò cực kỳ quan trọng. Một hệ thống dự báo chính xác không chỉ giúp các tổ chức tín dụng giảm thiểu rủi ro tín dụng mà còn hỗ trợ xây dựng chính sách cho vay phù hợp với từng nhóm khách hàng, nâng cao hiệu quả hoạt động và tối ưu hóa lợi nhuận.

Trong bối cảnh dữ liệu ngày càng phong phú và phức tạp, các phương pháp truyền thống dần bộc lộ hạn chế trong việc xử lý quan hệ phi tuyến và vấn đề mất cân bằng dữ liệu. Do

đó, việc ứng dụng các mô hình học máy (*Machine Learning*) vào dự đoán rủi ro tín dụng trở thành xu hướng tất yếu nhằm khai thác tối đa giá trị từ dữ liệu và cải thiện độ chính xác dự báo. Nghiên cứu này tập trung vào việc xây dựng và so sánh hiệu suất của nhiều mô hình phân loại khác nhau, đồng thời ứng dụng công cụ giải thích mô hình **SHAP (SHapley Additive exPlanations)** để phân tích tầm quan trọng của các biến đầu vào đối với kết quả dự đoán. Thông qua đó, nghiên cứu đưa ra các nhận định và khuyến nghị giúp các tổ chức tài chính hiểu rõ hơn về các yếu tố dẫn đến rủi ro tín dụng, hỗ trợ xây dựng hệ thống kiểm soát rủi ro thông minh.

Để thực hiện mục tiêu trên, chúng tôi triển khai thực nghiệm với các mô hình phổ biến bao gồm Logistic Regression, Decision Tree, SVM, MLP, KNN, Random Forest, LightGBM, Naive Bayes, XGBoost và CatBoost trên bộ dữ liệu thực tế. Sau khi tối ưu hóa tham số thông qua thực nghiệm, chúng tôi tiến hành đánh giá và so sánh hiệu suất của các mô hình này nhằm lựa chọn phương pháp tối ưu nhất cho bài toán dự đoán rủi ro tín dụng. Nghiên cứu kỳ vọng sẽ cung cấp cơ sở tham chiếu hữu ích cho việc triển khai các giải pháp phân tích dữ liệu tiên tiến trong quản trị rủi ro tín dụng, góp phần nâng cao tính minh bạch và hiệu quả hoạt động của ngành tài chính – ngân hàng.

II. CÁC NGHIÊN CỨU LIÊN QUAN

Trong những năm gần đây, bài toán dự đoán rủi ro tín dụng đã thu hút sự quan tâm lớn từ cộng đồng nghiên cứu, dẫn đến sự chuyển dịch mạnh mẽ từ các phương pháp thống kê truyền thống sang các mô hình học máy hiện đại.

Đi đầu trong xu hướng này, **Shiqi Yang (2025) [1]** đã tối ưu hóa dự báo rủi ro bằng cách kết hợp các mô hình Ensemble như XGBoost, LightGBM và Random Forest với kỹ thuật giải thích SHAP. Kết quả thực nghiệm cho thấy các mô hình Boosting đạt hiệu suất vượt trội với $AUC > 0.92$, đồng thời chỉ ra "Lịch sử thanh toán" và "Tỷ lệ nợ trên thu nhập" là những yếu tố rủi ro then chốt, khẳng định việc tích hợp SHAP giúp đảm bảo cả độ chính xác lẫn tính minh bạch trong quản trị rủi ro.

Tiếp nối hướng tiếp cận này, **Rambod Rahmani (2024) [2]** đề xuất một chiến lược chấm điểm tín dụng toàn diện, trong đó mô hình XGBoost đạt hiệu suất tối ưu với $AUC > 0.85$. Bằng cách sử dụng SHAP để xác định các chỉ báo quan trọng như "Số tháng quá hạn" và "Số lượng khoản vay hiện tại", nghiên cứu đã nâng cao tính giải trình ở cả cấp độ toàn cục và cục bộ, góp phần xây dựng hệ thống quản trị rủi ro có trách nhiệm. Song song đó, **Yandan Tan (2023) [3]** cũng nhấn mạnh vai trò của học máy có tính giải thích khi chứng minh LightGBM và CatBoost vượt trội về tốc độ và độ chính xác so với Neural Networks trên dữ liệu bảng. Thông qua phân tích SHAP, tác giả chỉ ra mối tương quan phi tuyến mạnh mẽ của các biến "Tình trạng việc làm" và "Số tiền vay" với rủi ro vỡ nợ, hỗ trợ các định chế tài chính đáp ứng yêu cầu pháp lý về tính giải trình của thuật toán.

Mặc dù các mô hình Ensemble mang lại hiệu năng cao, **Yujia Chen (2023) [4]** đã đưa ra cảnh báo về tác động tiêu cực của mất cân bằng dữ liệu đối với tính ổn định của các kỹ thuật giải thích như LIME và SHAP. Nghiên cứu dựa trên dữ liệu vay thế chấp tại Anh chỉ ra rằng khi tỷ lệ vỡ nợ giảm xuống dưới 5%, độ tin cậy của thứ hạng và giá trị đóng góp của các đặc trưng bị suy giảm đáng kể. Do đó, tác giả nhấn mạnh sự cần thiết của việc thận trọng khi giải trình các mô hình "hộp đen" để tránh các quyết định sai lệch hoặc vi phạm pháp lý về tính minh bạch. Tổng hợp lại, các công trình nghiên cứu trên đã đặt nền móng quan trọng cho việc ứng dụng các phương pháp Ensemble và kỹ thuật SHAP, đồng thời mở ra những thách thức mới trong việc xử lý dữ liệu thực tế nhằm nâng cao hiệu quả dự báo rủi ro tín dụng.

III. PHƯƠNG PHÁP (METHOD)

Nghiên cứu được triển khai theo ba bước chính: (i) **tiền xử lý dữ liệu** nhằm chuẩn hóa và tăng chất lượng đầu vào; (ii) **huấn luyện mô hình** với các thuật toán học máy phổ biến; và (iii) **đánh giá** toàn diện bằng các thước đo hiệu suất và phân tích tầm quan trọng đặc trưng.

A. Bộ dữ liệu

Nghiên cứu sử dụng bộ dữ liệu **Home Credit Default Risk**, một cơ sở dữ liệu tài chính thực tế được cung cấp nhằm giải quyết bài toán dự đoán rủi ro vỡ nợ của khách hàng vay. Dữ liệu này có cấu trúc phức tạp bao gồm nhiều bảng con liên kết với nhau để phản ánh toàn diện chân dung khách hàng, từ thông tin cơ bản và nhân khẩu học như tuổi tác, nghề nghiệp, thu nhập, tình trạng hôn nhân, cho đến lịch sử tín dụng chi tiết cùng trạng thái của các khoản vay hiện tại. Đặc biệt, bộ dữ liệu còn tích hợp các chỉ số điểm tín dụng từ các nguồn bên ngoài và các hành vi tài chính liên quan để cung cấp góc nhìn đa chiều về khả năng thanh toán của người vay.

Bảng chính của bộ dữ liệu chứa hàng trăm nghìn quan sát, trong đó mỗi bản ghi tương ứng với một khách hàng hoặc một đơn vay cụ thể kèm theo *nhân nhị phân* xác định trạng thái vỡ nợ. Các đặc trưng đầu vào bao gồm cả biến số liên tục và biến rời rạc, đòi hỏi quy trình xử lý dữ liệu nghiêm ngặt để đảm bảo tính nhất quán. Việc sử dụng nguồn dữ liệu đa dạng này không chỉ giúp mô hình như XGBoost đạt được hiệu suất

$AUC = 0.763$ mà còn cho phép các công cụ như SHAP phân tích sâu sắc tầm quan trọng của các yếu tố như EXT_SOURCE đối với rủi ro tín dụng.


B. Tiền xử lý dữ liệu

Quá trình tiền xử lý dữ liệu được thực hiện nhằm đảm bảo tính nhất quán giữa các tập huấn luyện và kiểm tra, xử lý dữ liệu thiếu, ngoại lệ, và chuẩn bị đặc trưng cho mô hình. Dựa trên các kỹ thuật chuẩn hóa dữ liệu được đề xuất bởi **Phạm Đình Khánh [5]**, quy trình bắt đầu với việc xử lý các biến phân loại (*Handling Categorical*) thông qua phương pháp **Grouping (Risk-based)** để gom nhóm các giá trị dựa trên mức độ rủi ro nhằm giảm độ phân mảnh dữ liệu. Tiếp theo, kỹ thuật **One-Hot Encoding** được áp dụng để chuyển đổi các biến phân loại thành dạng nhị phân giúp mô hình có thể tính toán, đồng thời thực hiện **Align Columns** để đảm bảo sự đồng nhất về các cột đặc trưng giữa tập huấn luyện và tập kiểm tra.

Đối với các biến số (*Handling Numerical*), nghiên cứu thực hiện **Outlier Capping (1%-99%)** nhằm giới hạn các giá trị ngoại lệ trong khoảng phần trăm từ 1 đến 99, từ đó giảm thiểu ảnh hưởng tiêu cực của các giá trị cực đoan. Việc xử lý dữ liệu thiếu được thực hiện thông qua **Median Imputation** bằng cách điền giá trị trung vị để duy trì phân bố gốc của dữ liệu, kết hợp với công cụ **Robust Scaler** để chuẩn hóa dữ liệu số và giảm tác động của các ngoại lệ còn sót lại trong quá trình huấn luyện.

Trong giai đoạn kỹ thuật đặc trưng (*Feature Engineering*), chúng tôi tiến hành lựa chọn 20 đặc trưng có tương quan cao nhất với biến mục tiêu (**Select Top 20 Correlated Features**) để giảm chiều dữ liệu hiệu quả. Ngoài ra, các đặc trưng bậc cao và tương tác giữa các biến được tạo ra thông qua kỹ thuật **Polynomial + Interaction** nhằm tăng cường khả năng biểu diễn các mối quan hệ phức tạp cho mô hình.

Sau khi hoàn tất quy trình tiền xử lý, dữ liệu được chia theo tỷ lệ **80/20** bằng phương pháp *Stratified Split* để đảm bảo phân bố nhân vỡ nợ giữa các tập là cân bằng. Kết quả sau xử lý cho thấy tập huấn luyện (**Train**) bao gồm 246,008 mẫu, tập kiểm tra (**Validation**) có 61,503 mẫu và tập thử nghiệm (**Test**) đạt 48,774 mẫu, tất cả đều đồng nhất ở số lượng 381 đặc trưng. Việc thiết lập dữ liệu quy mô lớn này là nền tảng quan trọng giúp mô hình XGBoost đạt được các chỉ số hiệu năng tối ưu như $AUC = 0.763$ và $F1 = 0.3159$.



Hình 1. Khung mô hình tổng thể Tiền xử lý dữ liệu

C. Mô hình và huấn luyện

Trong nghiên cứu này, mỗi mô hình được tinh chỉnh với một thông số then chốt để tối ưu hóa hiệu suất trên bộ dữ liệu mất cân bằng. Đối với **XGBoost**, thông số `scale_pos_weight` được thiết lập ở mức 6.75 nhằm tăng cường khả năng nhận diện nợ xấu mà không làm giảm độ chính xác tổng thể. Các mô hình dựa trên cây như **Decision Tree** và **Random Forest** được kiểm soát độ sâu (`max_depth`) lần lượt là 10 và 12 để tránh hiện tượng "học vẹt" dữ liệu nhiễu. **Logistic Regression** và **CatBoost** cùng sử dụng chiến lược 'balanced' (tự động cân bằng trọng số lớp) để đối phó với tình trạng lớp nợ xấu chiếm tỷ lệ rất thấp. Đối với **SVM**, tham số điều chuẩn C được tối ưu hóa nhằm xác định siêu phẳng phân tách hiệu quả trong không gian phi tuyến thông qua hàm nhân (Kernel). Trong khi đó, **KNN** tập trung vào việc lựa chọn số lượng láng giềng k tối ưu để đảm bảo tính ổn định của cơ chế bỏ phiếu trên dữ liệu đã được chuẩn hóa. Với các mạng thần kinh như **MLP**, cấu hình tầng ẩn (128, 64) đóng vai trò quyết định trong việc mô hình hóa các đặc trưng tài chính phi tuyến. Cuối cùng, **XGBoost** nổi bật với chỉ số AUC cao nhất (0.7628) khi được thiết lập `max_depth = 5`, còn **LightGBM** tập trung vào số lượng lá (`num_leaves = 31`) để quản lý độ phức tạp, trong khi **Naive Bayes** yêu cầu tiền xử lý bằng `Quantile Transformer` để đảm bảo dữ liệu tuân thủ giả định phân phối chuẩn.

a) **Logistic Regression**: Logistic Regression là một mô hình hồi quy phổ biến được sử dụng để dự báo xác suất của các biến phụ thuộc dạng nhị phân (0 hoặc 1). Khác với hồi quy tuyến tính, mô hình này sử dụng hàm Sigmoid để ánh xạ giá trị thực về khoảng xác suất $[0, 1]$. Quá trình thực thi mô hình bao gồm ba giai đoạn chính:

- 1) **Thiết lập hàm tuyến tính**: Mô hình tạo ra một tổ hợp tuyến tính từ các đặc trưng đầu vào X_i để tính toán giá trị logit (z):

$$z = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

Trong đó, các hệ số β_i thể hiện trọng số và mức độ ảnh hưởng của từng yếu tố đối với rủi ro vỡ nợ.

- 2) **Ánh xạ qua hàm Sigmoid**: Để chuyển đổi giá trị z thành xác suất nằm trong khoảng $[0, 1]$, mô hình sử dụng hàm Sigmoid:

$$P(y = 1|X) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

Hàm này tạo ra một đường cong hình chữ S, giúp phân tách dữ liệu mượn mà. Khi z lớn, xác suất P tiến gần về 1 (vỡ nợ), và ngược lại khi z rất nhỏ, P sẽ tiến về 0.

- 3) **Ước lượng và Phân loại**: Mô hình sử dụng phương pháp *Ước lượng hợp lệ cực đại (MLE)* để tìm bộ hệ số β sao cho xác suất dự báo khớp nhất với dữ liệu thực tế. Sau đó, ngưỡng cắt (Threshold) 0.5 được áp dụng để phân loại khách hàng.

b) **Decision Tree**: Decision Tree (Cây quyết định) là một thuật toán học có giám sát mạnh mẽ, mô phỏng quá trình ra quyết định của con người thông qua cấu trúc phân cấp hình

cây. Mô hình thực hiện phân chia dữ liệu từ các câu hỏi tổng quát tại nút gốc đến các kết luận cụ thể tại các nút lá thông qua ba bước chính:

- 1) **Lựa chọn thuộc tính phân tách**: Tại mỗi nút, thuật toán tìm kiếm đặc trưng và ngưỡng phân chia tối ưu nhằm giảm tối đa độ hỗn tạp (impurity) của dữ liệu [cite: 181]. Quá trình này sử dụng các thước đo toán học phổ biến bao gồm chỉ số Gini và Entropy:

$$\text{Gini}(S) = 1 - \sum_c p_c^2, \quad \text{Entropy}(S) = - \sum_c p_c \log p_c$$

Trong đó p_c là tỷ lệ mẫu thuộc lớp c tại nút S . Các thuộc tính giúp dữ liệu trở nên "tinh khiết" nhất sẽ được ưu tiên lựa chọn để phân nhánh [cite: 184].

- 2) **Phân tách dữ liệu đệ quy**: Sau khi chọn được biến quan trọng nhất, không gian dữ liệu được chia thành các vùng đồng nhất hơn. Quá trình này lặp lại liên tiếp tại các nút nội bộ (internal nodes), mỗi nút thực hiện một phép kiểm tra trên một thuộc tính mới để liên tục thu hẹp phạm vi phân loại [cite: 184, 196].
- 3) **Hình thành nút lá và dự báo**: Quá trình phân tách dừng lại khi đạt được các điều kiện như: dữ liệu trong nút hoàn toàn đồng nhất, cây đạt độ sâu tối đa (max depth), hoặc số lượng mẫu tại nút quá ít để tiếp tục chia nhỏ. Các điểm dừng cuối cùng này được gọi là nút lá (leaf nodes), nơi nhãn lớp chiếm đa số sẽ được dùng làm kết quả dự báo cho các mẫu dữ liệu mới [cite: 184].

Để ngăn chặn hiện tượng quá khớp (overfitting), cấu trúc cây thường được kiểm soát thông qua việc giới hạn độ sâu hoặc áp dụng các kỹ thuật cắt tỉa (pruning) [cite: 191, 202].

c) **Support Vector Machine (SVM)**: SVM là một mô hình phân loại mạnh mẽ hoạt động bằng cách tìm kiếm một siêu phẳng (hyperplane) tối ưu để phân tách các lớp dữ liệu trong không gian đa chiều. Mục tiêu của SVM là tối đa hóa khoảng cách (margin) giữa siêu phẳng và các điểm dữ liệu gần nhất của mỗi lớp, gọi là các vector hỗ trợ (support vectors). Hàm quyết định của SVM có dạng:

$$f(x) = \text{sign} \left(\sum_i \alpha_i y_i K(x_i, x) + b \right)$$

Trong đó:

- x_i là các vector hỗ trợ và y_i là nhãn lớp tương ứng.
- α_i và b là các tham số được tối ưu hóa trong quá trình huấn luyện.
- $K(x_i, x)$ là hàm nhân (Kernel), giúp xử lý dữ liệu phi tuyến bằng cách ánh xạ chúng vào không gian đặc trưng có số chiều cao hơn.

d) **Multilayer Perceptron (MLP)**: MLP là một mạng thần kinh nhân tạo cấu trúc tầng, bao gồm tầng đầu vào, một hoặc nhiều tầng ẩn và tầng đầu ra. Mỗi tầng chứa các nút (neurons) kết nối với nhau thông qua các trọng số. Quá trình hoạt động của MLP dựa trên hai giai đoạn chính:

- 1) **Lan truyền xuôi (Forward Propagation):** Tính toán giá trị tại mỗi neuron dựa trên tổng trọng số và hàm kích hoạt:

$$a = \sigma \left(\sum_j w_j x_j + b \right)$$

Trong đó w là trọng số, b là độ lệch và σ là hàm kích hoạt phi tuyến (như ReLU hoặc Sigmoid).

- 2) **Lan truyền ngược (Backpropagation):** Sử dụng thuật toán tối ưu hóa để cập nhật trọng số dựa trên sai số giữa giá trị dự báo và thực tế nhằm tối thiểu hóa hàm mất mát (Loss Function).

e) **K-Nearest Neighbors (KNN):** KNN là một thuật toán học máy dựa trên khoảng cách, hoạt động theo nguyên tắc láng giềng gần nhất. Đối với một quan sát mới, mô hình sẽ tìm k mẫu dữ liệu trong tập huấn luyện có khoảng cách gần nhất và thực hiện phân loại dựa trên đa số nhãn của các mẫu này. Khoảng cách phổ biến nhất được sử dụng là khoảng cách Euclidean:

$$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Trong đó:

- x và y là hai điểm dữ liệu trong không gian n chiều.
- k là số lượng láng giềng được chọn (một siêu tham số quan trọng).
- Việc chuẩn hóa dữ liệu là bắt buộc đối với KNN vì các đặc trưng có thang đo khác nhau sẽ ảnh hưởng sai lệch đến việc tính toán khoảng cách.

f) **Random Forest:** Random Forest là một phương pháp học kết hợp (Ensemble Learning) dựa trên kỹ thuật Bagging, xây dựng một tập hợp gồm M cây quyết định $\{T_1, T_2, \dots, T_M\}$ độc lập trong quá trình huấn luyện. Kết quả dự báo cuối cùng cho bài toán phân loại được xác định bằng cơ chế bỏ phiếu đa số (Majority Voting):

$$\hat{y} = \arg \max_{c \in \{0,1\}} \sum_{m=1}^M I(T_m(x) = c)$$

Trong đó $I(\cdot)$ là hàm chỉ thị. Cấu trúc và cơ chế tối ưu của mô hình dựa trên các hàm toán học sau:

- **Cơ chế Bagging (Bootstrap Aggregating):** Mỗi cây được huấn luyện trên một tập dữ liệu con D_m lấy mẫu ngẫu nhiên có thay thế từ tập gốc D với xác suất chọn một mẫu là $1/N$.
- **Hàm tối ưu hóa nút phân chia:** Tại mỗi nút, mô hình chọn đặc trưng j và ngưỡng s sao cho tối thiểu hóa độ hỗn tạp (Impurity). Chỉ số Gini thường được sử dụng:

$$\text{Gini}(S) = 1 - \sum_{c=0}^1 p_c^2$$

Trong đó p_c là tỷ lệ mẫu thuộc lớp c tại nút S .

- **Feature Randomness:** Khác với cây quyết định thông thường, Random Forest chỉ chọn ngẫu nhiên $m \approx \sqrt{n}$ đặc trưng từ tổng số n đặc trưng để tìm điểm phân chia tối ưu, giúp giảm sự tương quan giữa các cây.

Mô hình này được đánh giá cao nhờ khả năng xử lý dữ liệu bảng có số chiều cao và cung cấp các độ đo về tầm quan trọng của đặc trưng thông qua mức giảm trung bình của chỉ số Gini (Mean Decrease Gini).

g) **LightGBM (Light Gradient Boosting Machine):** LightGBM là một khung tăng cường độ dốc (Gradient Boosting) cải tiến, sử dụng các kỹ thuật tối ưu hóa để tăng tốc độ huấn luyện và giảm mức sử dụng bộ nhớ. Thuật toán tối ưu hóa hàm mục tiêu thông qua khai triển Taylor bậc hai:

$$\mathcal{L}^{(t)} \simeq \sum_{i=1}^n [g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i)] + \Omega(f_t)$$

Các bước thực thi chính bao gồm: 1)

- 1) **Khởi tạo:** Bắt đầu với một hàm dự báo cơ sở $f_0(x)$.
- 2) **Tính toán Gradient và Hessian:** Tại mỗi vòng lặp t , tính đạo hàm bậc nhất (g_i) và bậc hai (h_i) của hàm mất mát đối với dự báo của vòng lặp trước.
- 3) **Kỹ thuật GOSS (Gradient-based One-Side Sampling):** Giữ lại các mẫu có gradient lớn và lấy mẫu ngẫu nhiên các mẫu có gradient nhỏ để giảm kích thước dữ liệu.
- 4) **Phát triển cây theo Leaf-wise:** Thay vì phát triển cây theo từng tầng, LightGBM chọn lá có mức giảm tổn thất (Loss reduction) lớn nhất để phân tách. Công thức tính toán mức độ lợi thông tin (Gain) được thu nhỏ để phù hợp với độ rộng cột:

$$\text{Gain} = \frac{1}{2} \left[\frac{(\sum g_L)^2}{\sum h_L + \lambda} + \frac{(\sum g_R)^2}{\sum h_R + \lambda} - \frac{(\sum g_L + \sum g_R)^2}{\sum h_L + \sum h_R + \lambda} \right]$$

- 5) **Cập nhật mô hình:** Cộng dồn dự báo của cây mới vào mô hình tổng thể: $f_t(x) = f_{t-1}(x) + \eta f_t(x)$.

h) **Naive Bayes:** Naive Bayes là thuật toán phân loại dựa trên xác suất, sử dụng định lý Bayes với giả định các đặc trưng độc lập. Quy trình thực hiện gồm các bước: 1)

- 1) **Tính toán xác suất tiên nghiệm $P(c)$:** Ước lượng tỷ lệ các lớp (vỡ nợ và không vỡ nợ) trong tập huấn luyện:

$$\hat{P}(c) = \frac{N_c}{N}$$

i) **Naive Bayes:** Naive Bayes là thuật toán phân loại dựa trên xác suất, sử dụng định lý Bayes với giả định các đặc trưng độc lập. Quy trình thực hiện gồm các bước:

- 1) **Tính toán xác suất tiên nghiệm $P(c)$:** Ước lượng tỷ lệ các lớp (vỡ nợ và không vỡ nợ) trong tập huấn luyện:

$$\hat{P}(c) = \frac{N_c}{N}$$

- 2) **Tính toán khả năng (Likelihood) $P(x_i|c)$:** Với các biến liên tục, thường giả định phân phối Gaussian:

$$P(x_i|c) = \frac{1}{\sqrt{2\pi\sigma_c^2}} \exp \left(-\frac{(x_i - \mu_c)^2}{2\sigma_c^2} \right)$$

- 3) **Áp dụng giả định độc lập:** Tính toán xác suất chung cho bộ đặc trưng X :

$$P(X|c) = \prod_{i=1}^n P(x_i|c)$$

- 4) **Tính xác suất hậu nghiệm $P(c|X)$:** Dựa trên định lý Bayes (bỏ qua mẫu số $P(X)$ vì nó là hằng số cho mọi lớp):

$$P(c|X) \propto P(c) \prod_{i=1}^n P(x_i|c)$$

- 5) **Phân loại:** Gán nhãn cho quan sát mới vào lớp có xác suất hậu nghiệm cao nhất (Maximum A Posteriori - MAP).

j) **XGBoost (eXtreme Gradient Boosting):** XGBoost là một thuật toán tối ưu hóa dựa trên phương pháp Gradient Boosting, sử dụng kỹ thuật khai triển Taylor bậc hai để tối ưu hóa hàm mất mát. Hàm mục tiêu của XGBoost tại vòng lặp thứ t được định nghĩa như sau:

$$\mathcal{L}^{(t)} = \sum_{i=1}^n l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) + \Omega(f_t)$$

Trong đó:

- l là hàm mất mát đo lường sự khác biệt giữa giá trị thực y_i và dự báo $\hat{y}_i$.
- $\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$ là thành phần điều chuẩn (regularization) với T là số lượng lá và w là trọng số các lá, giúp kiểm soát độ phức tạp của cây.
- Thuật toán tối ưu bằng cách xấp xỉ hàm mất mát qua đạo hàm bậc nhất g_i (gradient) và bậc hai h_i (hessian), giúp quá trình hội tụ nhanh và chính xác hơn trên dữ liệu tập huấn luyện phức tạp.

k) **CatBoost (Categorical Boosting):** CatBoost là một thuật toán tăng cường độ đặc biệt hiệu quả với dữ liệu định danh nhờ cơ chế xử lý biến phân loại thông minh và cấu trúc cây đối xứng. Điểm khác biệt cốt lõi của CatBoost nằm ở hàm xử lý biến định danh thông qua kỹ thuật Ordered Target Statistics:

$$\hat{x}_{i,k} = \frac{\sum_{j \in \sigma_{i,p}} [y_j = y_k] + a \cdot P}{\sum_{j \in \sigma_{i,p}} 1 + a}$$


Cơ chế này bao gồm:

- **Ordered Boosting:** Thay thế các giá trị định danh bằng trung bình của nhãn mục tiêu từ các quan sát trước đó trong một hoán vị ngẫu nhiên, giúp loại bỏ hiện tượng rò rỉ dữ liệu (target leakage).
- **Cấu trúc cây đối xứng (Oblivious Trees):** CatBoost xây dựng các cây cân bằng mà tại mỗi mức của cây, tất cả các nút đều sử dụng chung một điều kiện phân chia. Cấu trúc này giúp tối ưu hóa thời gian dự báo và giảm thiểu nguy cơ quá khớp.
- Mô hình sử dụng các hàm tổn thất như Logloss cho bài toán phân loại nhị phân, đảm bảo tính ổn định cao ngay cả khi không tinh chỉnh nhiều siêu tham số.

D. Đánh giá

Để phản ánh toàn diện năng lực của các mô hình trong bài toán dự báo rủi ro tín dụng, nghiên cứu sử dụng các thước đo chuẩn hóa sau:

a) **ROC-AUC (Area Under the Receiver Operating Characteristic Curve):** ROC-AUC là chỉ số đo lường khả năng phân biệt giữa các lớp (vỡ nợ và an toàn) của mô hình.



Hình 2. Biểu đồ đánh giá mô hình AUC

- **Định nghĩa:** AUC là diện tích nằm dưới đường cong ROC, biểu diễn mối tương quan giữa tỷ lệ dương tính thật (TPR) và tỷ lệ dương tính giả (FPR) tại các ngưỡng khác nhau. Giá trị AUC nằm trong khoảng $[0, 1]$.
- **Mục đích:** Đánh giá hiệu suất tổng thể của mô hình độc lập với ngưỡng phân loại (*threshold*), đặc biệt hữu ích khi tập dữ liệu bị mất cân bằng.
- **Ý nghĩa tài chính:** AUC phản ánh khả năng xếp hạng rủi ro; xác suất mô hình gán điểm rủi ro cao hơn cho một khách hàng thực sự vỡ nợ so với một khách hàng tốt.
- b) **Precision (Độ chính xác dự báo):** Precision tập trung vào tính chính xác của các quyết định từ chối cho vay nhằm tối ưu hóa lợi nhuận cho ngân hàng.
- **Định nghĩa:** Là tỷ lệ giữa số lượng khoản vay thực sự vỡ nợ trên tổng số hồ sơ được mô hình dự báo là rủi ro:


$$\text{Precision} = \frac{TP}{TP + FP}$$

- **Mục đích:** Đánh giá độ tin cậy của các “cảnh báo đỏ”. Precision cao đồng nghĩa với việc khi hệ thống báo động vỡ nợ, xác suất rủi ro thực tế là rất lớn.
- **Ý nghĩa tài chính:** Giúp giảm thiểu sai lầm loại I (từ chối nhầm khách hàng tốt). Precision thấp gây lãng phí chi phí cơ hội, mất doanh thu từ lãi vay và ảnh hưởng tiêu cực đến trải nghiệm khách hàng.
- c) **Recall (Độ hồi tưởng / Khả năng nhận diện):** Recall là thước đo quan trọng nhất trong quản trị rủi ro hệ thống, tập trung vào việc bảo vệ nguồn vốn gốc.
- **Định nghĩa:** Là tỷ lệ giữa số lượng khoản vay vỡ nợ được mô hình nhận diện thành công trên tổng số các khoản vỡ nợ thực tế:

$$\text{Recall} = \frac{TP}{TP + FN}$$

- **Mục đích:** Đo lường năng lực truy quét rủi ro, đảm bảo hệ thống không bỏ sót các trường hợp mất khả năng thanh toán tiềm ẩn.
- **Ý nghĩa tài chính:** Ngăn chặn sai lầm loại II (bỏ sót khách hàng xấu). Trong ngân hàng, việc để lọt một ca vỡ nợ dẫn đến nguy cơ mất trắng vốn gốc, gây thiệt hại nặng nề hơn nhiều so với việc mất lãi từ một giao dịch đơn lẻ.

d) **F1-Score (Chỉ số trung bình điều hòa):** F1-Score là thước đo kết hợp giữa Precision và Recall, cung cấp một giá trị duy nhất đại diện cho sự cân bằng giữa khả năng nhận diện chính xác và khả năng bao phủ rủi ro của mô hình.



Hình 3. Biểu đồ đánh giá mô hình F1

- **Định nghĩa:** F1-Score là trung bình điều hòa (*harmonic mean*) của Precision và Recall. Công thức được xác định như sau:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- **Mục đích:** Chỉ số này được sử dụng để cung cấp cái nhìn tổng thể về hiệu năng mô hình, đặc biệt là khi có sự đánh đổi (trade-off) giữa việc ưu tiên không bỏ sót rủi ro (Recall) và việc đảm bảo dự báo chính xác (Precision).
- **Ý nghĩa trong bài toán vỡ nợ:** Do dữ liệu tín dụng thường bị mất cân bằng nghiêm trọng (tỷ lệ khách hàng vỡ nợ rất thấp so với nhóm an toàn), các chỉ số như Accuracy (Độ chính xác tổng quát) thường bị gây nhiễu. F1-Score trở thành thước đo khách quan nhất để so sánh năng lực của các mô hình dự báo rủi ro khác nhau trên cùng một tập dữ liệu không cân bằng.

Việc tối ưu hóa F1-Score giúp định chế tài chính duy trì được sự hài hòa giữa mục tiêu an toàn nguồn vốn (giảm thiểu nợ xấu) và mục tiêu tăng trưởng kinh doanh (giảm thiểu việc từ chối nhầm khách hàng tiềm năng).

e) **Giải thích mô hình bằng giá trị SHAP (SHapley Additive exPlanations):** Để giải quyết vấn đề "hộp đen" của các mô hình học máy phức tạp như XGBoost hay LightGBM, nghiên cứu ứng dụng phương pháp SHAP dựa trên lý thuyết trò chơi phối hợp. Phương pháp này phân bổ sự đóng góp của

từng đặc trưng đầu vào vào kết quả dự báo cuối cùng thông qua giá trị Shapley:

$$\phi_i = \sum_{S \subseteq \{x_1, \dots, x_n\} \setminus \{x_i\}} \frac{|S|!(n - |S| - 1)!}{n!} [f(S \cup \{x_i\}) - f(S)]$$

Trong đó:

- $f(S)$ là giá trị dự báo của mô hình khi chỉ có tập hợp các đặc trưng S .
- ϕ_i là giá trị đóng góp (SHAP value) của đặc trưng x_i .

Việc ứng dụng SHAP mang lại hai giá trị cốt lõi trong quản trị rủi ro tín dụng:

- 1) **Diễn giải toàn cục (Global Importance):** Định lượng mức độ ảnh hưởng trung bình của từng đặc trưng (ví dụ: điểm tín dụng bên ngoài, thu nhập) đối với khả năng vỡ nợ trên toàn bộ tập dữ liệu. Điều này giúp ngân hàng nhận diện các yếu tố rủi ro then chốt để xây dựng chính sách cấp tín dụng.
- 2) **Diễn giải cục bộ (Local Explanations):** Phân tích chi tiết lý do tại sao một hồ sơ vay cụ thể bị dự báo là rủi ro. Điều này đảm bảo tính minh bạch và công bằng, cho phép các tổ chức tài chính giải trình rõ ràng các quyết định từ chối cho vay theo yêu cầu của pháp luật.

Phương pháp này giúp chuyển đổi các mô hình phức tạp thành các công cụ hỗ trợ ra quyết định có thể hiểu được, kết hợp giữa hiệu năng dự báo cao và khả năng giải trình minh bạch.


IV. KẾT QUẢ

Các thí nghiệm trong nghiên cứu này được triển khai trên nền tảng điện toán đám mây Google Colab, cung cấp môi trường tính toán mạnh mẽ hỗ trợ GPU, giúp tối ưu hóa quá trình huấn luyện và đánh giá các mô hình học sâu và học máy phức tạp. Hệ thống thực nghiệm được thiết lập với cấu hình phần cứng bao gồm CPU Intel(R) Xeon(R) xung nhịp 2.20 GHz, GPU NVIDIA Tesla T4 với 16 GB VRAM và 12 GB RAM, đảm bảo khả năng xử lý hiệu quả các tập dữ liệu lớn và các thuật toán đòi hỏi tài nguyên cao.


Về môi trường phần mềm, nghiên cứu sử dụng ngôn ngữ lập trình Python phiên bản 3.10 kết hợp với các thư viện chuyên dụng để xây dựng hệ thống dự báo. Trong đó, thư viện *scikit-learn* được dùng để triển khai các thuật toán học máy truyền thống như Logistic Regression, Decision Tree, SVM, KNN và Naive Bayes. Đối với các mô hình học máy nâng cao theo phương pháp *Ensemble Learning*, chúng tôi ứng dụng các thư viện chuyên biệt bao gồm *XGBoost*, *LightGBM* và *CatBoost*. Để phân tích định lượng tầm quan trọng của các đặc trưng đầu vào, thư viện *SHAP* đã được tích hợp nhằm mang lại tính giải thích cho mô hình. Ngoài ra, các công cụ *Matplotlib* và *Seaborn* cũng được sử dụng để trực quan hóa các kết quả thực nghiệm và biểu đồ phân tích dữ liệu một cách trực quan.

Toàn bộ quy trình xử lý dữ liệu và huấn luyện được thực hiện trực tiếp trên môi trường đám mây, đảm bảo tính linh hoạt và khả năng mở rộng cao trong suốt quá trình thực nghiệm. Các tham số của mô hình được tinh chỉnh kỹ lưỡng thông qua


kỹ thuật tìm kiếm lưới (*Grid Search*) nhằm xác định cấu hình tối ưu nhất cho bài toán dự báo rủi ro tín dụng. Hiệu suất của các mô hình sau đó được đánh giá toàn diện dựa trên các chỉ số chính bao gồm *AUC*, *Recall*, *Precision* và *F1-score* để đảm bảo tính khách quan và độ tin cậy của kết quả dự báo cuối cùng.




Hình 4. Kết quả Ma trận nhầm lẫn của Logistic Regression




Hình 5. Kết quả Ma trận nhầm lẫn của Decision Tree




Hình 6. Kết quả Ma trận nhầm lẫn của SVM




Hình 7. Kết quả Ma trận nhầm lẫn của MLP




Hình 8. Kết quả Ma trận nhầm lẫn của KNN




Hình 9. Kết quả Ma trận nhầm lẫn của Random Forest




Hình 10. Kết quả Ma trận nhầm lẫn của LightGBM



Hình 13. Kết quả Ma trận nhầm lẫn của CatBoost



Hình 11. Kết quả Ma trận nhầm lẫn của Naive Bayes



Hình 12. Kết quả Ma trận nhầm lẫn của XGBoost

Model	AUC	Recall	Precision	F1
Logistic Regression	0.7481	0.6121	0.1777	0.2754
Decision Tree	0.6975	0.5797	0.1539	0.2433
SVM	0.7273	0.6413	0.156	0.251
MLP	0.7415	0.002	0.5882	0.004
Random Forest	0.7413	0.4524	0.2091	0.286
KNN	0.7162	0.5907	0.1553	0.2459
LightGBM	0.7321	0	0	0
Naive Bayes	0.6766	0.7827	0.1104	0.1935
XGBoost	0.7628	0.3889	0.2639	0.3141
CatBoost	0.7606	0.579	0.1954	0.2922

Hình 14. Kết quả đánh giá tổng hợp các mô hình

Từ kết quả thực nghiệm được trình bày tại Hình 14, có thể thấy sự khác biệt rõ rệt về hiệu suất giữa các mô hình học máy trong bài toán dự đoán vỡ nợ tín dụng.

Các mô hình truyền thống như **Logistic Regression** và **Decision Tree** cho thấy hiệu suất tổng thể còn hạn chế. Logistic Regression đạt chỉ số *AUC* khá tốt (0.7481) và *Recall* cao (0.6121), tuy nhiên *Precision* thấp (0.1777) dẫn đến *F1-score* chỉ đạt 0.2754. Điều này cho thấy mặc dù mô hình có khả năng nhận diện khách hàng xấu nhưng lại gặp sai lầm loại I (từ chối nhầm khách hàng tốt) khá cao.

Đối với các mô hình láng giềng và xác suất, **KNN** và **Naive Bayes** ghi nhận chỉ số *Recall* ấn tượng (lần lượt là 0.5907 và 0.7827). Tuy nhiên, *Precision* của hai mô hình này ở mức rất thấp (0.1553 và 0.1104), phản ánh khả năng tổng quát hóa hạn chế khi xử lý dữ liệu tín dụng phức tạp và đa chiều. Đặc biệt, mô hình **MLP**, dù sở hữu *AUC* (0.7415) và *Precision* (0.5882) cao, nhưng lại có *Recall* gần như bằng không (0.002), khiến *F1-score* không đáng kể (0.004). Kết quả này chỉ ra rằng MLP không phù hợp với cấu hình hiện tại của bộ dữ liệu này.

Ngược lại với các phương pháp truyền thống, các thuật toán dựa trên *Gradient Boosting* thể hiện ưu thế vượt trội về hiệu suất tổng thể trong bài toán này. Trong đó, mô hình **XGBoost** nổi bật khi đạt chỉ số *AUC* cao nhất hệ thống (0.7628) cùng *F1-score* tối ưu (0.3141). Mặc dù chỉ số *Recall* (0.3889) của XGBoost không phải là cao nhất so với các mô hình khác,

nhưng chỉ số *Precision* (0.2639) lại vượt trội hoàn toàn, giúp thiết lập sự cân bằng cần thiết giữa việc quản trị rủi ro tín dụng và tối ưu hóa chi phí cơ hội cho tổ chức tài chính.

Bên cạnh đó, **CatBoost** cũng cho thấy kết quả rất ổn định với *AUC* đạt 0.7606 và *F1-score* ở mức 0.2922, qua đó khẳng định năng lực xử lý dữ liệu bằng hiệu quả của thuật toán này trong thực tế. Tuy nhiên, trong điều kiện thực nghiệm hiện tại, mô hình **LightGBM** lại chưa đạt được kết quả khả quan khi các chỉ số chính đều tiệm cận mức 0. Hiện tượng này có thể xuất phát từ vấn đề về sự hội tụ của thuật toán hoặc do cấu hình siêu tham số chưa thực sự tối ưu cho đặc thù của bộ dữ liệu Home Credit.

Tổng kết lại, các phương pháp *Ensemble* dựa trên *Gradient Boosting* đã chứng minh được khả năng mạnh mẽ trong việc nắm bắt các mối quan hệ phi tuyến phức tạp và duy trì độ ổn định cao trước hiện tượng mất cân bằng dữ liệu nghiêm trọng. Với sự kết hợp hài hòa giữa năng lực phân loại chính xác và tính thực tiễn cao trong vận hành kinh doanh, **XGBoost** nổi bật như một lựa chọn tối ưu nhất cho hệ thống dự báo rủi ro tín dụng trong nghiên cứu này.

Ngoài các so sánh tổng quát, nghiên cứu này cũng tiến hành thực nghiệm để xem xét tác động của tham số *max_depth* (độ sâu tối đa của cây) đến hiệu suất của mô hình tối ưu nhất là XGBoost. Việc điều chỉnh độ sâu của cây đóng vai trò then chốt trong việc cân bằng giữa khả năng học các mối quan hệ phức tạp và việc kiểm soát hiện tượng quá khớp (*overfitting*).

Max_Depth	AUC	Recall	Precision	F1
6	0.7628	0.3889	0.2639	0.3144
5	0.763	0.4006	0.2607	0.3159
4	0.7623	0.4068	0.257	0.315
3	0.7618	0.4121	0.2538	0.3141


Hình 15. Đánh giá hiệu năng mô hình dựa trên sự thay đổi của độ sâu tối đa

Kết quả thực nghiệm cho thấy hiệu suất của mô hình có sự thay đổi rõ rệt khi tiến hành điều chỉnh tham số *max_depth*. Cụ thể, cấu hình tối ưu nhất đạt được tại giá trị *max_depth* = 5, với các chỉ số ấn tượng bao gồm *AUC* = 0.763, *Recall* = 0.4006, *Precision* = 0.2607 và *F1-score* = 0.3159. Độ sâu này được xem là ngưỡng giúp mô hình đạt được sự cân bằng lý tưởng giữa độ phức tạp của cấu trúc cây và khả năng tổng quát hóa trên dữ liệu thực tế. Ngược lại, khi độ sâu quá nhỏ (*max_depth* = 3), mô hình rơi vào hiện tượng *underfitting*; mặc dù chỉ số *Recall* đạt mức cao nhất (0.4121) nhưng *Precision* lại giảm xuống còn 0.2538, dẫn đến *F1-score* chỉ dừng lại ở mức 0.3141. Điều này cho thấy với cấu trúc cây nông, mô hình chưa thể khai thác hết được các mối quan hệ phi tuyến phức tạp tồn tại trong dữ liệu tín dụng.

Trong trường hợp tăng độ sâu cây lên mức 6, dù chỉ số *AUC* vẫn duy trì ổn định ở mức tốt (0.7628) và *Precision* có sự gia tăng nhẹ (0.2639), nhưng chỉ số *Recall* lại bị sụt giảm đáng

kể xuống còn 0.3889, kéo theo *F1-score* giảm xuống 0.3144. Xu hướng này minh chứng cho nguy cơ *overfitting*, khi việc tăng độ phức tạp của cây không mang lại cải thiện hiệu suất thực tế mà còn có thể làm suy giảm khả năng dự báo trên tập dữ liệu kiểm tra. Tóm lại, tham số *max_depth* đóng vai trò then chốt trong việc tinh chỉnh hiệu suất; giá trị tối ưu cho bài toán vỡ nợ tín dụng trong nghiên cứu này được xác định nằm trong khoảng từ 4 đến 5, trong đó mức độ sâu bằng 5 mang lại sự hài hòa nhất giữa các chỉ số đo lường rủi ro.

Cuối cùng, nghiên cứu này sử dụng phương pháp SHAP (*SHapley Additive exPlanations*) để phân tích chuyên sâu cơ chế ra quyết định của mô hình, giúp chuyển đổi mô hình "hộp đen" thành một hệ thống có tính giải thích cao. Trước hết, kết quả phân tích tầm quan trọng toàn cục của các đặc trưng (*global feature importance*) được thể hiện chi tiết tại Hình ??, cung cấp cái nhìn tổng quát về những biến số có tác động mạnh mẽ nhất đến khả năng vỡ nợ của khách hàng.




Hình 16. Đánh giá hiệu năng mô hình dựa trên sự thay đổi của độ sâu tối đa

Dựa trên phân bố giá trị SHAP được trình bày trong Hình 16, nghiên cứu đã xác định được các đặc trưng cốt lõi chi phối quyết định dự báo của mô hình. Kết quả phân tích cho thấy hai đặc trưng có mức ảnh hưởng trung bình (mean |SHAP value|) cao nhất vượt trội là *EXT_SOURCE_3_EXT_SOURCE_2* và *EXT_SOURCE_3_EXT_SOURCE_1*. Đây là các chỉ số tổng hợp từ nguồn điểm tín dụng bên ngoài, phản ánh hành vi lịch sử và hiệu suất tín dụng của khách hàng, đóng vai trò then chốt trong việc xác định rủi ro vỡ nợ cũng như duy trì tính ổn định của mô hình dự báo.

Bên cạnh các chỉ số tín dụng, nhóm đặc trưng liên

quan đến khoản vay như *AMT_CREDIT* (số tiền vay) và *AMT_GOODS_PRICE* (giá trị hàng hóa) cũng giữ mức quan trọng đáng kể, minh chứng rằng quy mô khoản vay và giá trị tài sản liên quan có mối liên hệ mật thiết với khả năng thanh toán thực tế của khách hàng. Trong khi đó, các đặc trưng nhân khẩu học và xã hội như *DAYS_EMPLOYED* (thời gian làm việc), *DAYS_BIRTH* (độ tuổi), và giới tính (*CODE_GENDER*) mặc dù có ảnh hưởng nhất định nhưng tác động tương đối yếu khi so sánh với nhóm chỉ số tín dụng tổng hợp. Các yếu tố khác như trình độ học vấn, tình trạng hôn nhân và sự thay đổi thông tin liên lạc tuy phản ánh mức độ ổn định kinh tế - xã hội của người vay nhưng không phải là những biến chi phối chính trong cơ chế ra quyết định của mô hình này. Ngược lại, các biến về mật độ dân số khu vực, dấu tài liệu và một số biến phụ khác thể hiện tác động rất nhỏ, gần như không đáng kể đến kết quả dự báo cuối cùng.

Tổng kết lại, mô hình chủ yếu dựa vào các điểm tín dụng từ nguồn bên ngoài và thông tin tài chính trực tiếp của khoản vay để đánh giá rủi ro vỡ nợ, thay vì phụ thuộc quá mức vào các biến tĩnh truyền thống. Kết quả này nhấn mạnh giá trị thực tiễn của việc sử dụng các mô hình học máy tinh chỉnh như XGBoost trong việc nhận diện rủi ro tín dụng hiện đại, nơi các mối quan hệ phi tuyến giữa dữ liệu tài chính đóng vai trò quyết định. Ngoài ra, nghiên cứu này cũng cung cấp biểu đồ phụ thuộc (*dependency graph*) để thể hiện chi tiết mức độ ảnh hưởng phi tuyến của các đặc trưng đến kết quả dự đoán, như được minh họa cụ thể trong Hình 17.



Hình 17. Tác động của các đặc trưng hàng đầu đến xác suất vỡ nợ


Để làm rõ hơn mối quan hệ giữa giá trị của các đặc trưng và hướng tác động đến kết quả dự báo, nghiên cứu tiến hành phân tích biểu đồ mật độ SHAP, qua đó cung cấp cái nhìn trực quan về sự tương tác giữa giá trị biến số

và mức độ đóng góp vào xác suất vỡ nợ. Kết quả cho thấy hai đặc trưng kết hợp *EXT_SOURCE_3_EXT_SOURCE_2* và *EXT_SOURCE_3_EXT_SOURCE_1* có tác động lớn nhất đến mô hình với giá trị SHAP phân bố rộng, chủ yếu nằm ở phía âm khi giá trị đặc trưng cao (biểu thị qua màu hồng). Điều này minh chứng rằng khách hàng có điểm tín dụng bên ngoài càng tốt thì rủi ro vỡ nợ càng giảm đáng kể, đồng thời thể hiện đặc tính phi tuyến ổn định khi ở vùng điểm cao, sự thay đổi giá trị SHAP trở nên nhẹ hơn, phản ánh cách mô hình đánh giá rủi ro đối với nhóm khách hàng uy tín một cách thận trọng.

Trái ngược với nhóm chỉ số tín dụng, các đặc trưng như *AMT_CREDIT* và *AMT_GOODS_PRICE* lại cho thấy xu hướng khi giá trị đặc trưng cao thường tập trung ở vùng SHAP dương, nghĩa là các khoản vay có quy mô lớn và giá trị hàng hóa cao tỷ lệ thuận với việc gia tăng xác suất vỡ nợ. Trong khi đó, các đặc trưng như *AMT_ANNUITY*, loại hình tổ chức, trình độ học vấn (*Higher education*) và giới tính chỉ duy trì mức ảnh hưởng trung bình đến kết quả dự báo. Các biến số khác như tuổi xe (*OWN_CAR_AGE*), dấu tài liệu hoặc thời gian thay đổi thông tin liên lạc có tác động rất nhỏ, gần như không đáng kể đến tổng thể dự báo của hệ thống.

Nhìn chung, biểu đồ mật độ này minh chứng rằng mô hình không phụ thuộc vào một biến số duy nhất mà xem xét mối quan hệ kết hợp phức tạp giữa nhiều đặc trưng, đặc biệt là các nguồn điểm tín dụng bên ngoài, để đưa ra dự báo rủi ro vỡ nợ một cách toàn diện. Kết quả này khẳng định tính ổn định và khả năng tổng quát hóa của mô hình XGBoost trong môi trường dữ liệu thực tế, giúp các tổ chức tài chính có cái nhìn sâu sắc hơn về các yếu tố rủi ro tiềm ẩn.

Sau khi đã phân tích cơ chế ra quyết định của mô hình thông qua SHAP, nghiên cứu tiến hành triển khai thực nghiệm trên tập dữ liệu kiểm tra độc lập gồm 48,744 hồ sơ để đánh giá khả năng ứng dụng thực tế. Kết quả phân phối xác suất rủi ro được thể hiện qua Hình 18, minh chứng cho khả năng phân tách rõ rệt của mô hình giữa các nhóm đối tượng khách hàng khác nhau.



Hình 18. Phân phối xác suất vỡ nợ trên tập dữ liệu Test

Dựa trên việc tối ưu hóa chỉ số *F1-score*, nghiên cứu thiết lập ngưỡng quyết định (*threshold*) tại mức **0.55** để cân bằng giữa mục tiêu quản trị rủi ro và hiệu quả kinh doanh. Theo quy tắc này, những hồ sơ có xác suất rủi ro từ 0.55 trở lên

(tương ứng với điểm tín dụng nội bộ từ 450 trở xuống) sẽ bị hệ thống tự động từ chối do tiềm ẩn rủi ro cao, trong khi các hồ sơ có xác suất thấp hơn sẽ được phê duyệt cho vay.

Kết quả dự báo trên tập dữ liệu Test				
SK_ID_CURR	TARGET_PROB	CREDIT_SCORE	DECISION	
0	0.220414	779	DUYỆT	
1	0.523006	476	DUYỆT	
2	0.095216	904	DUYỆT	
3	0.159614	840	DUYỆT	
4	0.499632	500	DUYỆT	
5	0.182437	817	DUYỆT	
6	0.068400	931	DUYỆT	
7	0.240017	759	DUYỆT	
8	0.056512	943	DUYỆT	
9	0.378025	621	DUYỆT	
10	0.247570	752	DUYỆT	
11	0.192929	807	DUYỆT	
12	0.551458	448	TỪ CHỐI	
13	0.456401	543	DUYỆT	
14	0.244716	755	DUYỆT	
15	0.551722	448	TỪ CHỐI	
16	0.290043	709	DUYỆT	
17	0.178410	821	DUYỆT	
18	0.300716	699	DUYỆT	
19	0.146505	853	DUYỆT	
20	0.074602	925	DUYỆT	
21	0.048185	951	DUYỆT	
22	0.157508	842	DUYỆT	

Hình 19. Danh sách hồ sơ mẫu và quyết định tín dụng của hệ thống

Việc chuyển đổi từ kết quả dự báo thô sang các trạng thái quyết định cụ thể như *Duyệt* hoặc *Từ chối* giúp các chuyên viên tín dụng có cơ sở dữ liệu tin cậy để ra quyết định nhanh chóng. Sự kết hợp giữa khả năng dự báo chính xác của XGBoost và tính minh bạch từ SHAP giúp hệ thống không chỉ đạt hiệu quả về mặt kỹ thuật mà còn đáp ứng được yêu cầu về tính giải trình trong lĩnh vực tài chính ngân hàng hiện đại.

Tiếp nối phần triển khai dự báo, nghiên cứu trình bày một trường hợp điển hình mô phỏng quy trình thẩm định tự động đối với nhóm khách hàng "vùng xám" (*borderline*) để minh chứng năng lực thực thi của hệ thống. Như được minh họa tại Hình 20, hồ sơ khách hàng mã số 81930 có xác suất rủi ro dự báo là **55.00%**, đạt đúng ngưỡng quy định **0.55**. Với điểm tín dụng tương ứng là 449/1000, hệ thống đưa ra quyết định **TỪ CHỐI VAY** do tiềm ẩn rủi ro cao.

```
⚡ Đang quét dữ liệu để tìm hồ sơ điển hình...
✅ Đã tìm thấy hồ sơ demo phù hợp.

>>> DEMO: KHÁCH HÀNG VÙNG XÁM (BORDERLINE) <<<

=====
===== KẾT QUẢ THẨM ĐỊNH TỰ ĐỘNG =====
=====
👤 Khách hàng ID: 81930
📊 Điểm tín dụng: 449 / 1000
📉 Xác suất rủi ro: 55.00%
🎯 Ngưỡng quy định: 0.55


-----
❌ QUYẾT ĐỊNH: TỪ CHỐI VAY (Rủi ro CAO)
=====

🔍 Đang phân tích lý do cho hồ sơ 81930...
```

Hình 20. Kết quả thẩm định tự động cho hồ sơ khách hàng 81930

Để đảm bảo tính minh bạch, nghiên cứu sử dụng biểu đồ *SHAP Waterfall* để phân tích lý do dẫn đến quyết định này (Hình 21). Kết quả cho thấy các đặc trưng tổ hợp như *EXT_SOURCE_3_EXT_SOURCE_2* (+0.5) và các biến tài

chính khác đóng vai trò then chốt trong việc đẩy xác suất rủi ro lên mức cảnh báo.



Hình 21. Phân tích lý do ra quyết định dựa trên SHAP cho hồ sơ 81930

Ngược lại, các yếu tố về trình độ học vấn (*Higher education*) và giá trị hàng hóa (*AMT_GOODS_PRICE*) lại có tác động kéo giảm rủi ro, nhưng không đủ để thay đổi quyết định cuối cùng. Quy trình này khẳng định khả năng của hệ thống trong việc cung cấp các căn cứ định lượng rõ ràng, hỗ trợ đắc lực cho các chuyên viên thẩm định trong việc giải trình các quyết định tín dụng phức tạp.

V. TỔNG KẾT

a) *Tổng kết nghiên cứu:* Trong nghiên cứu này, chúng tôi tập trung giải quyết vấn đề mất cân bằng lớp trong bộ dữ liệu Home Credit. Thay vì sử dụng các kỹ thuật lấy mẫu lại như SMOTE, chúng tôi đã áp dụng các giải pháp tích hợp sẵn trong mô hình, cụ thể là điều chỉnh trọng số lớp (*class weights*) để tăng cường khả năng nhận diện lớp thiểu số mà không làm biến đổi phân phối dữ liệu gốc.

Tuy nhiên, một thách thức quan trọng khác vẫn tồn tại là sự biến thiên giữa các miền (*cross-domain variability*). Thách thức này xuất hiện do các bảng con (*sub-tables*) biểu diễn đặc trưng theo những cách thức khác nhau, gây khó khăn cho mô hình trong việc học các mẫu nhất quán. Điều này ảnh hưởng trực tiếp đến hiệu suất và độ ổn định lâu dài của hệ thống dự báo vỡ nợ tín dụng.

b) *Hướng phát triển tương lai:* Trong tương lai, chúng tôi dự định nghiên cứu và áp dụng các kỹ thuật thích ứng miền không giám sát (*unsupervised domain adaptation*), chẳng hạn như các phương pháp điều chuẩn dựa trên tối ưu hóa vận chuyển (*Optimal Transport*) hoặc lý thuyết thông tin nhằm nâng cao năng lực của mô hình. Cụ thể, chúng tôi sẽ xem xét phương pháp *Joint Distribution Adaptation* (JDA) của **Mingsheng Long** [6] để thu hẹp khoảng cách phân phối cả về đặc trưng lẫn nhãn mục tiêu giữa các miền dữ liệu đa dạng. Đồng thời, việc áp dụng các kỹ thuật điều chuẩn dựa trên Entropy tương đối (KL Divergence) hoặc các phương pháp thích ứng miền tổng quát theo nghiên cứu của 1 bài báo với 1 trong các tác giả là **Abolfazl Farahani** [7] sẽ được thực hiện để nâng cao khả năng tổng quát hóa trên dữ liệu đa nguồn trong bài toán dự đoán vỡ nợ tín dụng.

Ngoài ra, chúng tôi cũng nghiên cứu kỹ thuật cắt tỉa dữ liệu (*data pruning*) như một chiến lược hỗ trợ cho việc điều

chỉnh trọng số lớp nhằm xử lý hiệu quả các bộ dữ liệu lớn và mất cân bằng. Theo các nghiên cứu của **Carla Vairetti [8]** về việc lựa chọn mẫu thông minh và tối ưu hóa tập dữ liệu huấn luyện, việc loại bỏ có chọn lọc các mẫu ít thông tin hoặc gây nhiễu có thể cải thiện đáng kể hiệu quả huấn luyện mà vẫn duy trì được độ ổn định của mô hình.

Kỹ thuật này được kỳ vọng sẽ đặc biệt hữu ích khi kết hợp với phương pháp trọng số lớp, giúp mô hình tập trung vào các biên giới quyết định (*decision boundaries*) quan trọng mà không bị xao nhãng bởi các điểm dữ liệu nhiễu trong lớp đa số. Cách tiếp cận này giúp tối ưu hóa hệ thống quản trị rủi ro tín dụng hiện đại, vừa đảm bảo tốc độ hội tụ, vừa tránh được các sai số do việc tạo dữ liệu nhân tạo gây ra.

TÀI LIỆU

- [1] S. Yang, Z. Huang, W. Xiao, and X. Shen, "Interpretable credit default prediction with ensemble learning and shap;" 5 2025. [Online]. Available: <http://arxiv.org/abs/2505.20815>
- [2] R. Rahmani, M. Parola, and M. G. C. A. Cimino, "A machine learning workflow to address credit default prediction;" 3 2024. [Online]. Available: <http://arxiv.org/abs/2403.03785>
- [3] Y. Tan, H. Zhu, JieWu, and H. Chai, "Tab-attention: Self-attention-based stacked generalization for imbalanced credit default prediction;" 12 2023. [Online]. Available: <http://arxiv.org/abs/2312.01688><http://dx.doi.org/10.3233/FAIA230532>
- [4] Y. Chen, R. Calabrese, and B. Martin-Barragan, "Interpretable machine learning for imbalanced credit scoring datasets," *European Journal of Operational Research*, vol. 312, pp. 357–372, 1 2024.
- [5] P. Đình Khánh, "Home credit default risk," 2018.
- [6] M. Long, J. Wang, G. Ding, J. Sun, and P. S. Yu, "Transfer feature learning with joint distribution adaptation," in *Proceedings of the IEEE International Conference on Computer Vision*. Institute of Electrical and Electronics Engineers Inc., 2013, pp. 2200–2207.
- [7] A. Farahani, S. Voghoei, K. Rasheed, and H. R. Arabnia, "A brief review of domain adaptation;" 10 2020. [Online]. Available: <http://arxiv.org/abs/2010.03978>
- [8] C. Vairetti, J. L. Assadi, and S. Maldonado, "Efficient hybrid oversampling and intelligent undersampling for imbalanced big data classification," *Expert Systems with Applications*, vol. 246, p. 123149, 7 2024. [Online]. Available: <https://www.sciencedirect.com/science/article/abs/pii/S0957417424000149>